

Análisis de la Geometría del Aprendizaje Profundo mediante Homología Persistente en Espacios Latentes

Luis Aguiar

18 de mayo de 2026

Resumen

Este informe presenta un enfoque metodológico basado en el Análisis Topológico de Datos (TDA) para estudiar la dinámica interna de una Red Neuronal Convolutiva (CNN) durante el proceso de entrenamiento. A través del cálculo de la homología persistente (H_0 y H_1) y la métrica de estabilidad de Wasserstein en los embeddings latentes, cuantificamos fenómenos estructurales que escapan a las métricas de rendimiento tradicionales como el *Accuracy*.

1. Introducción

El éxito de las redes neuronales profundas radica en su capacidad para transformar representaciones de datos complejas en espacios latentes linealmente separables. Sin embargo, el comportamiento interno de estos espacios a menudo se trata como una “caja negra”. Las métricas de evaluación tradicionales, como la precisión de prueba (*Accuracy*), solo reflejan el éxito en la frontera de decisión, ignorando la evolución geométrica y topológica intrínseca de las representaciones vectoriales.

Este trabajo se motiva en la necesidad de desarrollar herramientas de interpretabilidad cuantitativa. Estudiar cómo se esculpe el espacio latente permite evaluar la robustez del modelo, comprender los mecanismos de convergencia post-entrenamiento y abrir nuevas vías para el análisis no supervisado de la confianza en modelos de *Deep Learning*.

2. Trabajo Relacionado

El Análisis Topológico de Datos (TDA), y específicamente la homología persistente, ha emergido como un marco riguroso para caracterizar estructuras de datos multidimensionales. Carlsson (2009) sentó las bases de la topología aplicada a conjuntos de datos, demostrando que los datos poseen formas intrínsecas de baja dimensión en espacios de alta dimensión.

En el ámbito del aprendizaje profundo, trabajos como los de Naitzat et al. (2020) han demostrado empíricamente que las redes neuronales actúan reduciendo la complejidad topológica de los datos a medida que se avanza en las capas profundas. Por otro lado, la utilización de la distancia de Wasserstein para evaluar la estabilidad de diagramas de persistencia encuentra sus fundamentos en los teoremas de estabilidad de Cohen-Steiner et al. (2007). Este proyecto se alinea con dichas aproximaciones, implementando un pipeline dinámico para trackear el cambio época a época mediante librerías modernas como *Ripser* y *Persim*.

3. Dataset y Características

Para validar experimentalmente este enfoque, se utiliza el dataset **MNIST** (Modified National Institute of Standards and Technology). Este conjunto de datos consta de imágenes en escala de grises de 28×28 píxeles representando dígitos manuscritos del 0 al 9.

El dataset se divide estandarmente en un conjunto de entrenamiento de 60,000 imágenes y un conjunto de prueba de 10,000 imágenes. Las características de entrada corresponden a vectores normalizados de dimensión 784 (derivados de la matriz bidimensional original). Adicionalmente, para garantizar la consistencia en el cálculo topológico y mitigar la volatilidad muestral, se extrae un subconjunto fijo y balanceado de 2,000 instancias del set de entrenamiento para actuar como *snapshot* regular de los embeddings de la red a lo largo del tiempo.

4. Métodos

4.1. Entrada y Salida

La entrada al sistema consiste en mini-batches de tensores de dimensiones $[B, 1, 28, 28]$, donde B representa el tamaño del lote. La salida de la red es un vector de *logits* de dimensión 10, sobre el cual se aplica una función *Softmax* implícita mediante la función de pérdida para determinar la probabilidad de pertenencia a cada una de las clases de dígitos.

4.2. Arquitectura de la Red

Se implementa una Red Neuronal Convolutiva Estándar (**SimpleCNN**) con las siguientes capas jerárquicas:

1. **Capa Convolutiva 1:** Entrada de 1 canal, salida de 16 canales, kernel de 3×3 , *padding* de 1. Seguida de activación ReLU y MaxPool de 2×2 .
2. **Capa Convolutiva 2:** Entrada de 16 canales, salida de 32 canales, kernel de 3×3 , *padding* de 1. Seguida de activación ReLU y MaxPool de 2×2 .
3. **Capa Totalmente Conectada (Extracción):** Proyección lineal desde las características aplanadas a un espacio latente de **64 dimensiones** ($\mathbf{E} \in \mathbb{R}^{64}$). Este vector constituye el *embedding* de características objeto de estudio topológico.
4. **Capa de Clasificación Final:** Proyección lineal desde las 64 dimensiones del embedding hacia las 10 clases de salida.

4.3. Métricas de Evaluación y Análisis

El modelo se optimiza utilizando *Cross Entropy Loss* y el algoritmo Adam ($\alpha = 10^{-3}$) durante 10 épocas. Las métricas de monitoreo estructural implementadas son:

- **Precisión de Prueba (Test Accuracy):** Fracción de clasificaciones correctas.
- **Persistencia Total (H_0 Global e Intra-clase):** Suma de la longitud de las barras de vida de las componentes conexas tras una reducción de dimensionalidad mediante PCA a 30 componentes.
- **Distancia de Centroides:** Separación geométrica media euclidiana entre las medias vectoriales de cada clase calculada directamente en el espacio original de 64 dimensiones.
- **Distancia de Wasserstein (W_d):** Métrica de transporte óptimo aplicada sobre los diagramas de persistencia consecutivos para evaluar la estabilidad estructural época a época:

$$W_q(D_t, D_{t-1}) = \left(\inf_{\gamma} \sum_{x \in D_t} \|x - \gamma(x)\|_{\infty}^q \right)^{1/q} \quad (1)$$

5. Resultados y Discusión

Los experimentos computacionales arrojaron resultados cuantitativos de alta claridad respecto a la dinámica interna de la red. La Tabla 1 resume la evolución de las variables clave.

Cuadro 1: Consolidación de Métricas Geométricas, Topológicas y de Rendimiento.

Época	Test Acc	TP H_0 Global	TP H_0 Intra	Centroide Dist	Wasserstein H_0	Wasserstein H_1
1	0.9698	14934.5	1490.3	35.804	—	—
2	0.9803	15485.9	1531.1	38.764	718.02	284.14
3	0.9853	16790.1	1654.2	42.173	866.13	251.70
4	0.9862	17605.9	1730.3	43.324	296.66	224.41
5	0.9867	17713.6	1739.7	44.292	548.62	246.14
6	0.9893	18872.7	1847.8	46.334	272.79	238.96
7	0.9891	20974.1	2048.0	51.199	1328.72	314.01
8	0.9866	20708.8	2021.0	48.956	548.25	246.24
9	0.9877	21631.7	2106.7	50.762	1695.67	411.91
10	0.9889	23417.1	2276.4	54.386	248.17	271.88

5.1. Análisis Estadístico de Correlación

El cálculo del coeficiente de correlación de Pearson demostró que la **Persistencia Total Global** (H_0) mantiene una correlación casi perfecta de **0.987** con la **Distancia entre Centroides**. Esto valida de forma empírica que el TDA actúa como un indicador matemático riguroso de la dispersión y el aislamiento de las clases en alta dimensión sin requerir métricas de etiquetado directas.

Por otro lado, la correlación entre el *Test Accuracy* y la Persistencia Global se situó de manera moderada en **0.685**. Esto prueba el fenómeno del **aprendizaje post-convergencia**: a partir de la época 6 el rendimiento del clasificador entra en una meseta, pero el optimizador continúa esculpiendo agresivamente el espacio latente, incrementando la separación geométrica media en un 51 % (de 35.80 a 54.38).

5.2. Volatilidad Topológica y Estabilidad

El análisis dinámico mediante la distancia de Wasserstein revela que el proceso de aprendizaje no es lineal. Los picos masivos registrados en la distancia de Wasserstein para H_0 en la época 7 (1328,72) y época 9 (1695,67) evidencian reestructuraciones macroscópicas drásticas del espacio de características (crisis estructurales provocadas por el gradiente), seguidas de un desplome de volatilidad en la época 10 (248,17), lo que denota una maduración y estabilización topológica final del modelo.

6. Conclusiones

Este estudio permite concluir los siguientes puntos cardinales:

1. **Insuficiencia del Accuracy:** Las métricas funcionales de rendimiento ocultan transformaciones críticas del espacio latente. El modelo continúa optimizando sus márgenes de seguridad geométrica mucho después de alcanzar su precisión máxima.
2. **Fidelidad del TDA:** Se confirma la robustez de la Homología Persistente como proxy descriptivo del espacio de características, mostrando un acoplamiento estadístico robusto con la separación euclidiana clásica.

3. **Dinámica de Convergencia:** La distancia de Wasserstein identifica con éxito las discontinuidades del aprendizaje, distinguiendo entre fases de reordenamiento tectónico y fases de ajuste fino e isomorfismo estructural.

7. Repositorio de GitHub

`https://github.com/luiaguilar/proyecto\_redes\_neuronales`